

Recherche documentaire

Présenté par : Noé De Caestecker et Killian Darras


Stemmer de Porter

- Lecture du corpus de documents
- Structure sous forme de dictionnaire

ex : {logical=logic, logically=logic, logics=logic, etc ...}

Structure de l'index

- arbre 2-4 :



- rotation des mots : abc -> \$abc, c\$ab, bc\$\\$a

Structure de l'index

- pointeurs pour les rotations
- création des vecteurs
- normalisation (avec les normes stockées)

mot / idf	query	doc1	doc2
new / 0.5	0.5	0.5	
york / 0.75	0.75	0.9	
is / 0.2	0.2		0.4
good / 0.6	0.6		0.6

Correcteur d'orthographe

- Soundex avec le dictionnaire anglais

ex : {z352 = [zootomical,zotomically,zootomist]}

- Utilisation des Trigrammes

ex : unfortunately = {un,nf,fo,or,rt,tu,un,na,at,te,el,ly}

- Mesure de Jaccard